

BÁO CÁO ĐỒ ÁN

RAGHUB - TRỢ LÝ TRI THỨC NỘI BỘ DỰA TRÊN RAG

*Mô hình RAG Hub chạy hoàn toàn offline cho doanh nghiệp, sử dụng Ollama và
kỹ thuật Hybrid Retrieval + Reranking*

Môn học: CS315.F21.CN2.TTNT - Máy học nâng cao

GVHD: ThS. Đặng Việt Dũng

Sinh viên thực hiện:

MSSV	Họ và tên
25410104	Nguyễn Minh Nhật

TP. Hồ Chí Minh, 19 Tháng 6 năm 2026

TÓM TẮT

Tài liệu nội bộ doanh nghiệp (chính sách, hướng dẫn kỹ thuật, đặc tả API...) thường nằm rải rác, khiến nhân viên mất thời gian tìm kiếm và dễ trả lời sai do thiếu ngữ cảnh.

RagHub là một Proof of Concept (POC) cho một trợ lý hỏi-đáp nội bộ dựa trên kỹ thuật RAG (Retrieval-Augmented Generation), trả lời câu hỏi bằng ngôn ngữ tự nhiên kèm trích dẫn nguồn cụ thể (tài liệu, mục, trang). Xuất phát từ thực tế doanh nghiệp ngần ngại đưa tài liệu nội bộ nhạy cảm qua các mô hình AI công khai, đề án trình bày một mô hình **RAG Hub chạy hoàn toàn offline**, tự host toàn bộ mô hình AI cần thiết qua Ollama, expose dưới dạng API nội bộ để nhiều phòng ban có thể dùng chung và đồng bộ hoá việc quản lý tài liệu.

Hệ thống được xây dựng theo kế hoạch tuần tự gồm hai bước thử nghiệm kỹ thuật ban đầu và bảy giai đoạn xây dựng: từ khung hệ thống, nạp tài liệu, tạo vector ngữ nghĩa, đến quy trình tìm kiếm lai (hybrid retrieval: tìm theo ngữ nghĩa kết hợp tìm theo từ khoá chính xác, hợp nhất bằng Reciprocal Rank Fusion) và chấm lại độ liên quan (reranking) trước khi sinh câu trả lời streaming có trích dẫn. Toàn bộ các giai đoạn trong kế hoạch đã được hoàn thành, tạo ra một vòng end-to-end chạy thật: upload tài liệu -> theo dõi trạng thái xử lý -> xem trước cách chia đoạn -> hỏi-đáp có trích dẫn -> đánh giá chất lượng. Báo cáo cũng phân tích các thử thách thực tế khi đưa một hệ thống RAG từ quy mô POC sang vận hành thật tại doanh nghiệp - chất lượng dữ liệu không đồng nhất, tài liệu lỗi thời, bảo mật, và duy trì chất lượng theo thời gian - cùng đề xuất lộ trình phát triển tiếp theo để phát triển.

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI.....	1
1.1. Đặt Vấn Đề.....	1
1.2. Bối Cảnh Triển Khai Thực Tế Tại Doanh Nghiệp.....	1
1.3. Mục Tiêu Của Giai Đoạn POC	2
1.4. Phạm Vi Đề Án.....	2
CHƯƠNG 2. KẾ HOẠCH THỰC HIỆN.....	3
CHƯƠNG 3. KIẾN TRÚC HỆ THỐNG	5
CHƯƠNG 4. QUÁ TRÌNH THỰC HIỆN.....	8
CHƯƠNG 5. KẾT QUẢ ĐẠT ĐƯỢC SO VỚI KẾ HOẠCH.....	10
CHƯƠNG 6. CÔNG NGHỆ SỬ DỤNG VÀ LÝ DO LỰA CHỌN.....	11
CHƯƠNG 7. ĐO LƯỜNG CHẤT LƯỢNG	13
CHƯƠNG 8. THỬ THÁCH THỰC TẾ VÀ HƯỚNG PHÁT TRIỂN	14
8.1. Thử Thách Khi Vận Hành Ở Doanh Nghiệp Trong Thực Tế.....	14
8.2. Hướng Phát Triển Tiếp Theo	15
CHƯƠNG 9. KẾT LUẬN	16

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1. Đặt Vấn Đề

Tài liệu nội bộ của tổ chức (chính sách, hướng dẫn kỹ thuật, đặc tả API...) thường nằm rải rác ở nhiều nơi khác nhau. Khi cần trả lời một câu hỏi đơn giản, nhân viên phải tự tìm kiếm trong nhiều tài liệu - tốn thời gian và dễ trả lời sai do thiếu ngữ cảnh hoặc đọc nhầm bản cũ.

RagHub được xây dựng để giải quyết vấn đề này: một trợ lý hỏi-đáp nội bộ dùng kỹ thuật RAG (Retrieval-Augmented Generation), cho phép người dùng hỏi bằng ngôn ngữ tự nhiên và nhận câu trả lời **kèm trích dẫn nguồn cụ thể** (tài liệu nào, mục nào, trang nào) - không trả lời chung chung, không bịa thông tin, và luôn cho phép người dùng tự kiểm tra lại nguồn.

1.2. Bối Cảnh Triển Khai Thực Tế Tại Doanh Nghiệp

Trong thực tế triển khai tại doanh nghiệp, việc cho phép một mô hình AI công khai (public LLM) truy cập trực tiếp vào tài liệu nội bộ thường gặp sự e ngại đáng kể - phần lớn xuất phát từ lo ngại về bảo mật và quyền riêng tư dữ liệu (data privacy), đặc biệt với tài liệu chính sách, hợp đồng, hay thông tin vận hành nhạy cảm. Vì vậy, nhu cầu triển khai một hệ thống AI nội bộ chạy hoàn toàn offline (fully-offline AI) - không gửi bất kỳ dữ liệu nào ra ngoài hạ tầng do doanh nghiệp tự kiểm soát - đang ngày càng trở nên phổ biến và là một yêu cầu thực tế cần được tính đến từ đầu, không phải một tùy chọn thêm vào sau.

Đối với riêng kỹ thuật RAG, hai phần khó nhất trong toàn bộ pipeline luôn là **tiền xử lý tài liệu** (parse, chia đoạn sao cho giữ đúng ngữ cảnh) và **đánh giá chất lượng** (đo được retrieval/câu trả lời có đúng hay không một cách định lượng, không chỉ cảm tính) - đây cũng chính là hai phần được đầu tư kỹ nhất trong POC này. Ngoài ra, một hệ thống RAG hiếm khi vận hành độc lập một mình; nó thường cần đi kèm với một bộ quản lý tài liệu (Document Management) của doanh nghiệp để đảm bảo nguồn dữ liệu đầu vào có cấu trúc, được phân loại, và được làm mới đúng quy trình. Việc đưa RAG ra dưới dạng một API nội bộ và xây dựng nó thành một **“RAG Hub” trung tâm** - thay vì một ứng dụng chat đơn lẻ gắn cứng với một phòng ban - cho phép các bộ phận/phòng ban khác nhau trong doanh nghiệp chủ động khai thác cùng một hạ tầng tìm kiếm-trả lời, đồng thời đồng bộ hoá cách quản lý và chuẩn hoá tài liệu theo một quy chuẩn chung duy nhất, tránh tình trạng mỗi phòng ban tự xây một giải pháp riêng lẻ, rời rạc.

Đề án cá nhân này trình bày một mô hình **RAG Hub chạy hoàn toàn offline**, sử dụng Ollama để tự host các mô hình AI cần thiết, kết hợp một số kỹ thuật retrieval (tìm kiếm kết hợp, chấm lại độ liên quan) nhằm tối ưu hoá chất lượng cho một chatbot hỏi-đáp nội bộ - minh hoạ ở quy mô POC cho hướng tiếp cận nói trên.

1.3. Mục Tiêu Của Giai Đoạn POC

Mục tiêu của giai đoạn POC là trả lời một câu hỏi duy nhất, mang tính quyết định: **khả năng tìm đúng đoạn tài liệu liên quan (retrieval) có đủ chính xác để tin dùng không?** Đây là câu hỏi quan trọng nhất vì nó quyết định cả dự án có đáng để đầu tư tiếp thành sản phẩm chính thức hay không. Vì vậy POC ưu tiên làm kỹ phần tìm kiếm trước khi đầu tư vào giao diện đẹp hay tích hợp thêm kênh khác - những phần đó vô nghĩa nếu việc tìm kiếm tài liệu sai.

Quy mô giả định cho POC: khoảng 10 người dùng kiểm thử, 20–50 tài liệu.

1.4. Phạm Vi Đồ Án

Trong phạm vi của đồ án:

- Cho phép upload tài liệu ở nhiều định dạng phổ biến (PDF, Word, văn bản thuần, Markdown).
 - Tự động phân loại loại tài liệu dựa trên cấu trúc văn bản (heuristic theo cách trình bày heading), không cần gọi mô hình AI riêng cho việc phân loại để tránh tốn chi phí và thời gian mỗi lần upload.
 - Quy trình xử lý tài liệu: bóc tách nội dung văn bản → chia nhỏ thành các đoạn có ngữ cảnh đầy đủ → chuyển mỗi đoạn thành vector ngữ nghĩa → lưu trữ có cấu trúc.
 - Tính năng hỏi-đáp dạng chat: kết hợp tìm kiếm theo ngữ nghĩa và tìm kiếm theo từ khoá chính xác, sau đó chấm lại độ liên quan của các đoạn tìm được trước khi đưa vào sinh câu trả lời, trả lời theo dạng streaming (hiện dần như đang gõ).
 - Tính năng phản hồi (thích/không thích) gắn liền với đoạn tài liệu đã dùng để trả lời, phục vụ việc cải thiện chất lượng sau này.
 - Bộ công cụ đánh giá chất lượng: chạy thử trên một bộ câu hỏi mẫu có sẵn đáp án đúng, đo bằng số liệu cụ thể thay vì cảm tính.
-

CHƯƠNG 2. KẾ HOẠCH THỰC HIỆN

Kế hoạch xây dựng được chia thành hai bước thử nghiệm kỹ thuật ban đầu nhằm giảm rủi ro, tiếp theo là một chuỗi giai đoạn (phase) tuần tự, mỗi giai đoạn có tiêu chí hoàn thành (definition of done) rõ ràng - chỉ chuyển sang giai đoạn sau khi tiêu chí của giai đoạn trước đã được xác minh.

Bảng 2.1. Kế hoạch xây dựng theo từng giai đoạn

Giai đoạn	Nội dung kế hoạch	Tiêu chí hoàn thành đặt ra
Thử nghiệm 1	Xác minh cơ chế lưu trữ vector và tìm kiếm theo độ tương đồng hoạt động đúng	Chạy thử thành công, kết quả trả về đúng thứ tự độ tương đồng kỳ vọng
Thử nghiệm 2	Dựng thử dịch vụ chấm lại độ liên quan (reranker) độc lập	Dịch vụ chạy được, trả về kết quả sắp xếp hợp lý khi gọi thử
Giai đoạn 0	Dựng khung hệ thống, thiết kế cơ sở dữ liệu, kiểm tra kết nối	Hệ thống khởi động thành công, kiểm tra tình trạng (health check) trả về kết quả ổn
Giai đoạn 1	Upload → bóc tách văn bản → chia đoạn (chưa có vector)	Upload tài liệu thành công, đoạn tài liệu được lưu kèm đầy đủ thông tin nguồn gốc
Giai đoạn 2	Bổ sung bước tạo và lưu vector ngữ nghĩa	Mỗi đoạn tài liệu có vector tương ứng, có khả năng xử lý lại khi cần
Giai đoạn 3	Xây dựng quy trình tìm kiếm: tìm theo ngữ nghĩa → kết hợp tìm theo từ khoá → chấm lại độ liên quan	Tìm kiếm trả kết quả theo thứ hạng hợp lý; bật/tắt từng bước cho thấy sự khác biệt rõ rệt về chất lượng
Giai đoạn 4	Hỏi-đáp dạng chat, trả lời có trích dẫn, dạng streaming	Trả lời đúng kèm trích dẫn chính xác; câu hỏi ngoài phạm vi tài liệu bị từ chối thay vì bịa thông tin
Giai đoạn 5	Xây dựng giao diện quản trị và giao diện hỏi-đáp	Toàn bộ luồng sử dụng được trọn vẹn trên trình duyệt
Giai đoạn 6	Xây dựng bộ đánh giá chất lượng tự động	Chạy được trên bộ câu hỏi mẫu, ra số liệu đo lường cụ thể

Lý do sắp xếp thứ tự như trên: xử lý văn bản trước khi tạo vector (rẻ trước, tốn chi phí tính toán sau), tìm kiếm đơn giản trước khi thêm các lớp cải thiện chất lượng (mỗi bước chứng minh thêm giá trị trước khi thêm độ phức tạp), xây phần xử lý dữ liệu trước khi xây giao diện, và đánh giá chất lượng được làm sau cùng vì nó đo lường toàn bộ những gì đã xây.


CHƯƠNG 3. KIẾN TRÚC HỆ THỐNG

Hệ thống gồm bốn lớp chính, tách biệt rõ trách nhiệm:

- **Giao diện người dùng:** gồm một giao diện quản trị (theo dõi tài liệu, xem trước cách chia đoạn, cấu hình hệ thống) và một thành phần hỏi-đáp dạng chat được thiết kế độc lập, có thể nhúng vào nơi khác mà không phụ thuộc vào toàn bộ giao diện quản trị.
- **Tầng dịch vụ trung tâm:** tiếp nhận yêu cầu từ giao diện cũng như từ các hệ thống/ứng dụng khác gọi vào, điều phối toàn bộ logic nghiệp vụ.
- **Tầng xử lý nền:** chạy song song, đảm nhận việc xử lý tài liệu mới upload (bóc tách, chia đoạn, tạo vector) mà không làm người dùng phải chờ.
- **Tầng lưu trữ và các dịch vụ mô hình AI hỗ trợ:** một datastore duy nhất chứa cả thông tin tài liệu và dữ liệu vector (tránh phải đồng bộ giữa hai hệ thống lưu trữ riêng biệt), cùng các mô hình AI chạy tự chủ (self-host) phục vụ việc tạo vector ngữ nghĩa và sinh câu trả lời, và một dịch vụ riêng biệt chuyên trách việc chấm lại độ liên quan của kết quả tìm kiếm.

Nguyên tắc thiết kế trọng tâm: **việc nạp tài liệu (ingestion) và việc hỏi-đáp (query) là hai luồng xử lý hoàn toàn tách biệt**, chỉ chia sẻ nơi lưu trữ dữ liệu chung. Upload không bắt người dùng phải chờ xử lý xong - việc bóc tách, chia đoạn, tạo vector chạy nền; truy vấn hỏi-đáp luôn nhanh vì không bao giờ phải đợi xử lý tài liệu mới.

Phần xử lý nghiệp vụ được tổ chức theo nguyên tắc tầng phụ thuộc một chiều: phân định nghĩa khái niệm nghiệp vụ cốt lõi không phụ thuộc vào bất kỳ hạ tầng cụ thể nào (cơ sở dữ liệu, mô hình AI...); phần hiện thực hạ tầng phụ thuộc vào tầng cốt lõi đó; và tầng giao tiếp với bên ngoài (API, giao diện) phụ thuộc vào cả hai tầng trên. Cách tổ chức này giúp việc thay đổi một thành phần hạ tầng (ví dụ đổi nhà cung cấp mô hình AI) không ảnh hưởng tới logic nghiệp vụ.




Sơ đồ tổng thể các thành phần

Hình 3.1. Sơ đồ tổng thể các thành phần của hệ thống



Luồng nạp tài liệu

Hình 3.2. Luồng nạp tài liệu (ingestion — chạy nền)



Luồng hỏi-đáp

Hình 3.3. Luồng hỏi-đáp (query - thời gian thực)

CHƯƠNG 4. QUÁ TRÌNH THỰC HIỆN

Cả hai bước thử nghiệm kỹ thuật ban đầu đều đạt yêu cầu, xác nhận hai giả định cốt lõi của thiết kế hoạt động đúng trong thực tế trước khi đầu tư công xây toàn bộ hệ thống xung quanh chúng.

Toàn bộ các giai đoạn xây dựng tiếp theo đều đã được hoàn thành theo đúng trình tự kế hoạch:

- **Khung hệ thống và cơ sở dữ liệu** đã được dựng đầy đủ, có cơ chế kiểm tra tình trạng kết nối và cơ sở dữ liệu đã được khởi tạo đúng thiết kế.
- **Quy trình nạp tài liệu** hoạt động đầy đủ với ba loại file phổ biến nhất, có khả năng tự suy luận chiến lược chia đoạn phù hợp theo loại tài liệu (theo cấu trúc heading, theo mục, theo điểm cuối API...), tự động chuyển trạng thái xử lý và báo lỗi rõ ràng khi xử lý thất bại - không có tình trạng lỗi âm thầm.
- **Bước tạo vector ngữ nghĩa** đã được tích hợp, có khả năng chạy lại quá trình xử lý cho một tài liệu cụ thể khi cần tinh chỉnh, và lưu kèm thông tin mô hình đã dùng để tránh trộn lẫn dữ liệu từ các mô hình khác nhau.
- **Quy trình tìm kiếm** đã hoàn thiện đầy đủ ba lớp: tìm theo ngữ nghĩa, kết hợp tìm theo từ khoá chính xác, và chấm lại độ liên quan bằng một mô hình chuyên biệt - đúng theo thiết kế đặt ra ban đầu nhằm đạt độ chính xác cao hơn cách làm tìm-theo-vector-đơn-thuần phổ biến. Việc cấu hình các tham số tìm kiếm còn được làm tốt hơn dự kiến: thay vì cố định trong file cấu hình tĩnh, hệ thống cho phép chỉnh trực tiếp qua giao diện quản trị mà không cần khởi động lại.
- **Tính năng hỏi-đáp** hoạt động đầy đủ: trả lời theo dạng streaming, kèm trích dẫn cụ thể tới từng đoạn tài liệu đã dùng, có cơ chế chỉ trả lời dựa trên ngữ cảnh được cung cấp và từ chối khi không có thông tin liên quan. Một tính năng bổ sung không nằm trong phạm vi yêu cầu gốc cũng được thêm vào: khả năng viết lại câu hỏi cho rõ nghĩa khi người dùng hỏi tiếp trong một cuộc hội thoại nhiều lượt.
- **Giao diện sử dụng** đã hoàn thiện đầy đủ các màn hình cần thiết: tổng quan thống kê, upload, danh sách và chi tiết tài liệu (kèm xem trước cách chia đoạn để debug), cấu hình hệ thống, và màn hình đánh giá chất lượng. Thành phần hỏi-đáp được xây dựng như một khối độc lập, có thể nhúng vào giao diện quản trị hoặc tách ra phục vụ một kênh hoàn toàn khác mà không cần sửa lại.
- **Bộ đánh giá chất lượng** đã hoàn thiện, cho phép nạp bộ câu hỏi mẫu kèm đáp án đúng kỳ vọng, chạy lại toàn bộ quy trình một cách tự động và hiển thị kết quả theo từng câu hỏi cùng số liệu tổng hợp. Thiết kế dữ liệu cho phần đánh giá đã được tinh chỉnh qua nhiều lần điều chỉnh trước khi chốt phiên bản ổn định.

Ngoài các giai đoạn đã lên kế hoạch, một số tính năng bổ sung cũng đã được xây dựng:

- Một cơ chế xác thực đơn giản bằng khoá truy cập (API key), cho phép các hệ thống hoặc nhóm khác gọi vào tính năng hỏi-đáp như một dịch vụ trung tâm dùng chung, không bắt buộc phải đi qua giao diện quản trị.

- Khả năng quản trị “khuôn mẫu chia đoạn” theo từng loại tài liệu ngay trên giao diện, thay vì cố định cứng trong cấu hình tĩnh như thiết kế ban đầu.
 - Khả năng xuất dữ liệu đã xử lý (đoạn tài liệu, vector, thông tin mô hình đã dùng) ra file để có thể tái sử dụng trên một thiết bị khác không có kết nối liên tục, phục vụ các phương án triển khai tại biên (edge) trong tương lai.
-

CHƯƠNG 5. KẾT QUẢ ĐẠT ĐƯỢC SO VỚI KẾ HOẠCH

Bảng 5.1. So sánh mức độ hoàn thành với kế hoạch ban đầu

Nội dung kế hoạch	Mức độ hoàn thành	Ghi chú
Hai bước thử nghiệm kỹ thuật ban đầu	Đạt	
Khung hệ thống và cơ sở dữ liệu	Đạt	
Nạp tài liệu / bóc tách / chia đoạn	Đạt	
Tạo và lưu vector ngữ nghĩa	Đạt	
Quy trình tìm kiếm kết hợp + chấm lại độ liên quan	Đạt	Cấu hình động qua giao diện, vượt yêu cầu ban đầu
Hỏi-đáp có trích dẫn, dạng streaming	Đạt	Có thêm khả năng viết lại câu hỏi cho hội thoại nhiều lượt
Giao diện quản trị và hỏi-đáp	Đạt	Thành phần hỏi-đáp tách độc lập đúng thiết kế
Bộ đánh giá chất lượng	Đạt	Đã qua vài lần tinh chỉnh để chốt đúng cách đo

Toàn bộ các giai đoạn trong kế hoạch ban đầu đều đã được hiện thực đầy đủ và nhất quán với nhau. Mức độ hoàn thành tại thời điểm báo cáo là **đủ một vòng end-to-end chạy thật**: upload tài liệu → theo dõi trạng thái xử lý → xem trước cách chia đoạn → hỏi-đáp có trích dẫn → đánh giá chất lượng bằng số liệu cụ thể - đúng như mục tiêu đặt ra ở Chương 1.

CHƯƠNG 6. CÔNG NGHỆ SỬ DỤNG VÀ LÝ DO LỰA CHỌN

Bảng 6.1. Công nghệ sử dụng và lý do lựa chọn

Thành phần	Lựa chọn	Lý do
Nền tảng backend	Nền tảng web hiện đại, hỗ trợ xử lý bất đồng bộ tốt	Phù hợp cho pipeline phải gọi nhiều dịch vụ ngoài (mô hình AI, dịch vụ chậm lại độ liên quan) mà không bị nghẽn
Cơ sở dữ liệu	Một hệ quản trị cơ sở dữ liệu quan hệ có hỗ trợ lưu trữ và truy vấn vector tích hợp sẵn	Một datastore duy nhất chứa cả thông tin nghiệp vụ và dữ liệu vector - tránh phải đồng bộ giữa hai hệ thống lưu trữ riêng biệt, giảm điểm lỗi và công vận hành
Mô hình tạo vector ngữ nghĩa	Mô hình mã nguồn mở, tự host, chạy được trên CPU	Miễn phí, không phát sinh chi phí theo lượng sử dụng, dữ liệu nội bộ không gửi ra ngoài tổ chức - quan trọng với tài liệu chính sách/nội bộ nhạy cảm; giữ khả năng triển khai ở môi trường offline/biên về sau
Mô hình sinh câu trả lời	Mô hình mã nguồn mở tự host làm mặc định, có thể đổi sang mô hình trả phí qua một dòng cấu hình khi cần chất lượng cao hơn	Tự chủ dữ liệu, không phụ thuộc một nhà cung cấp duy nhất
Dịch vụ chậm lại độ liên quan	Một dịch vụ độc lập, tách riêng tiến trình	Loại mô hình này cần một cách vận hành khác so với mô hình sinh văn bản hoặc tạo vector - tách riêng để không phụ thuộc lẫn nhau và dễ thay thế
Giao diện người dùng	Thư viện giao diện hiện đại, có sẵn bộ component dựng nhanh	Phát triển nhanh, đủ component để dựng cả giao diện quản trị và giao diện hỏi-đáp

Việc tách các thành phần liên quan tới mô hình AI (tạo vector, sinh câu trả lời, chậm lại độ liên quan) thành các lớp giao tiếp trừu tượng - không gọi trực tiếp một SDK cụ thể

trong logic nghiệp vụ - là quyết định thiết kế có chủ đích: đổi nhà cung cấp mô hình chỉ là đổi cấu hình, không phải sửa code, tránh bị khoá cứng vào một nhà cung cấp duy nhất.

CHƯƠNG 7. ĐO LƯỜNG CHẤT LƯỢNG

Mục tiêu thành công đặt ra cho giai đoạn POC:

- **Tỷ lệ tìm đúng tài liệu trong nhóm kết quả hàng đầu vượt 80%** (đo chất lượng của bước tìm kiếm)
- **Độ chính xác trích dẫn trong câu trả lời cuối cùng vượt 80%** (đo chất lượng của bước sinh câu trả lời)
- **Thời gian trả lời ở mức trải nghiệm tốt cho phần lớn lượt hỏi, dưới 10 giây**, đo từ lúc hỏi đến khi có câu trả lời đầy đủ (có streaming để giảm cảm giác chờ đợi)

Việc tách riêng hai nhóm chỉ số chất lượng tìm kiếm và chất lượng câu trả lời có lý do kỹ thuật cụ thể: khi câu trả lời sai, nó cho biết nguyên nhân là **tìm sai tài liệu** hay **tìm đúng tài liệu nhưng sinh câu trả lời sai** - hai loại lỗi này cần hướng sửa hoàn toàn khác nhau, và việc đo lẫn vào một chỉ số duy nhất sẽ che mất nguyên nhân thật.

Bộ đánh giá cho phép nạp một bộ câu hỏi mẫu kèm đáp án đúng kỳ vọng từ trước, chạy lại toàn bộ quy trình một cách tự động, và hiển thị kết quả theo từng câu hỏi cùng số liệu tổng hợp. Bộ câu hỏi khởi điểm có quy mô nhỏ trên tài liệu mẫu, với mục tiêu mở rộng dần lên quy mô lớn hơn để đạt độ tin cậy thống kê đủ cho việc ra quyết định đầu tư tiếp.

CHƯƠNG 8. THỬ THÁCH THỰC TẾ VÀ HƯỚNG PHÁT TRIỂN

8.1. Thử Thách Khi Vận Hành Ở Doanh Nghiệp Trong Thực Tế

Một POC chạy tốt trên vài chục tài liệu mẫu không tự động đảm bảo vận hành tốt khi đưa vào dùng thật trong tổ chức. Một số thử thách thực tế cần lường trước:

- **Chất lượng tài liệu đầu vào không đồng nhất.** Tài liệu nội bộ thực tế thường có định dạng lộn xộn (bảng phức tạp, ảnh chụp chèn trong file, font/encoding khác nhau, file scan), không sạch như tài liệu mẫu dùng để kiểm thử. Việc bóc tách và chia đoạn có thể hoạt động tốt trên một tập mẫu nhưng xuống chất lượng đáng kể trên dữ liệu thật đa dạng hơn nhiều.
- **Tài liệu lỗi thời và xung đột thông tin.** Doanh nghiệp thường có nhiều phiên bản tài liệu tồn tại song song (chính sách cũ chưa bị xoá, file nháp lẫn với file chính thức). Một hệ thống chỉ tìm “đoạn liên quan nhất” mà không biết phân biệt bản mới/cũ có thể tự tin trích dẫn một nguồn đã hết hiệu lực — rủi ro nghiêm trọng hơn cả việc không tìm thấy thông tin, vì nó tạo cảm giác đáng tin cậy giả.
- **Khối lượng và tốc độ thay đổi tài liệu tăng theo thời gian.** Ở quy mô vài chục tài liệu, việc xử lý lại toàn bộ khi cần là chấp nhận được. Khi tài liệu tăng lên hàng nghìn và thay đổi liên tục (chính sách cập nhật hàng tuần), cần một quy trình làm mới index gọn nhẹ, theo từng phần thay đổi, không phải xử lý lại từ đầu mỗi lần.
- **Câu hỏi mơ hồ hoặc đa nghĩa trong thực tế.** Người dùng thật không hỏi rõ ràng như câu hỏi trong bộ đánh giá mẫu - viết tắt riêng của công ty, hỏi tắt, hỏi nhiều ý trong một câu, hoặc giả định ngữ cảnh mà hệ thống không có. Tỷ lệ trả lời đúng trên bộ câu hỏi mẫu chuẩn hoá thường cao hơn đáng kể so với khi tiếp xúc với cách hỏi thật của người dùng.
- **Áp lực đồng thời và chi phí hạ tầng khi tăng số người dùng.** Việc chạy mô hình AI tự host giúp tránh chi phí trả theo lượt gọi, nhưng đổi lại giới hạn bởi năng lực phần cứng sẵn có - nhiều người hỏi cùng lúc sẽ làm tăng thời gian chờ nếu hạ tầng không được tính toán dự phòng đủ, khác với dịch vụ AI trả phí có thể mở rộng gần như ngay lập tức (nhưng tốn chi phí biến đổi theo lượng dùng).
- **Bảo mật và quản trị dữ liệu nội bộ.** Một khi đưa vào dùng thật, câu hỏi “ai được hỏi gì, ai được xem nguồn nào” trở thành yêu cầu bắt buộc, không còn là tùy chọn như ở giai đoạn POC. Việc thiết kế dữ liệu đã chừa sẵn chỗ cho việc này giúp giảm rủi ro, nhưng phần thực thi (xác thực, phân quyền, ghi log truy cập) vẫn là khối lượng công việc đáng kể chưa được làm.
- **Duy trì chất lượng theo thời gian, không chỉ tại thời điểm ra mắt.** Chất lượng tìm kiếm và trả lời có thể xuống dần khi tài liệu mới được thêm vào mà không theo đúng cấu trúc đã tối ưu ban đầu, hoặc khi mô hình AI nền tảng được cập nhật phiên bản. Cần một quy trình theo dõi chất lượng định kỳ, không chỉ đo một lần khi nghiệm thu.
- **Niềm tin và mức độ chấp nhận của người dùng cuối.** Ngay cả khi hệ thống đạt độ chính xác cao về số liệu, người dùng thực tế cần thời gian để tin tưởng và hình

thành thói quen sử dụng thay cho cách tìm tài liệu cũ (hỏi đồng nghiệp, tìm file thủ công). Đây là thử thách về thay đổi hành vi, không phải thử thách kỹ thuật, nhưng quyết định mức độ thành công thực tế của dự án.

Đây là những rủi ro cần lường trước khi mở rộng từ quy mô POC sang vận hành thật, không phải dấu hiệu cho thấy hướng đi hiện tại sai - phần lớn các thử thách trên có hướng giải quyết đã biết (nêu ở mục kế tiếp), chỉ là chưa cần thiết phải làm ở giai đoạn chứng minh khái niệm.

8.2. Hướng Phát Triển Tiếp Theo

Bảng 8.1. Lộ trình phát triển đề xuất

Giai đoạn	Nội dung	Lý do cần thiết
Bảo mật & vận hành	Xác thực tập trung, phân quyền theo phòng ban (lọc ngay khi tìm kiếm nhờ thiết kế dữ liệu đã chuẩn bị sẵn), quản lý phiên bản tài liệu	Bắt buộc trước khi đưa cho người dùng thật ngoài nhóm test
Hạ tầng	Hệ thống hàng đợi xử lý riêng biệt, cơ chế lập chỉ mục chuyên dụng nêu khối lượng tài liệu tăng lớn, giám sát vận hành	Đảm bảo ổn định khi số người dùng và tài liệu tăng lên
Kênh tích hợp	Adapter cho các nền tảng chat nội bộ, thiết bị tại biên (kiosk)	Mở rộng kênh tiếp cận mà không cần sửa lại phần lõi đã xây
Liên tục	Mở rộng bộ câu hỏi đánh giá lên quy mô lớn hơn, theo dõi số liệu chất lượng định kỳ	Đảm bảo chất lượng không tụt khi thêm tài liệu mới

Chi phí vận hành dự kiến chủ yếu là hạ tầng máy chủ (đủ mạnh để chạy các mô hình AI tự host) vì các mô hình đang dùng không tính phí theo lượng sử dụng - khác biệt rõ so với phương án dùng dịch vụ AI trả phí theo lượng gọi khi mở rộng cho nhiều người dùng nội bộ.

CHƯƠNG 9. KẾT LUẬN

Đồ án đã hoàn thành toàn bộ các giai đoạn đặt ra trong kế hoạch ban đầu, từ các bước thử nghiệm kỹ thuật đầu tiên đến bộ đánh giá chất lượng cuối cùng, cho ra một hệ thống RAG chạy thật theo đúng nghĩa end-to-end - không phải mock hay demo tĩnh. Phần kỹ thuật rủi ro cao nhất của mọi dự án RAG - độ chính xác của bước tìm kiếm - đã được giải quyết bằng quy trình tìm kiếm kết hợp nhiều lớp cộng với chấm lại độ liên quan, đúng theo thiết kế đặt ra ban đầu, thay vì cách làm tìm-theo-vector-đơn-thuần thường không đạt độ chính xác đủ dùng thật.

So với kế hoạch ban đầu, thực tế triển khai còn vượt một số điểm: cấu hình tìm kiếm và chia đoạn chuyển từ tĩnh sang động qua giao diện quản trị, có thêm khả năng viết lại câu hỏi cho hội thoại nhiều lượt, và có cơ chế xác thực bằng khoá truy cập cho phép hệ thống khác gọi vào dùng chung.

Các phần còn lại để lên sản phẩm chính thức (bảo mật, vận hành ở quy mô lớn, mở rộng kênh tiếp cận) là công việc kỹ thuật đã biết rõ cách làm, không còn là rủi ro chưa biết - đây là sự khác biệt giữa một ý tưởng và một giải pháp đã được chứng minh khả thi, chỉ còn cần đầu tư để mở rộng.